

# Метод опорных векторов

Support Vector Machine (SVM)

# История

- Первые идеи метода были предложены еще в 1950-е годы.
- Метод был создан на основе статистической теории обучения
- Метод стал известен и популярен после замечательной статьи (Вапник и др.) в 1992 г.
- В настоящее время метод успешно используется во многих областях.
- Метод также был модифицирован для задач регрессии.

# Метод


- Метод опорных векторов решает задачу классификации.
- Каждый элемент данных - точка в  $m$ -мерном пространстве  $\mathbb{R}_m$ .
- Формально: есть точки  $x_i$ ,  $i = 1, \dots, m$ , у точек есть метки  $y_i \in \{-1, +1\}$ .

*Можно ли разделить данные гиперплоскостью и какая она?*


# Классификация данных

$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$  - линейная разделяющая функция  
(гиперплоскость)


$$g(x_1, \dots, x_m) = \sum_{i=1}^m w_i x_i + b$$




# Первый вариант




# Еще несколько вариантов



# Второй вариант



# Еще несколько вариантов






Оптимальная разделяющая гиперплоскость — это гиперплоскость, максимизирующая ширину **разделяющей полосы** и лежащая в середине этой полосы.


Иными словами, оптимальная разделяющая гиперплоскость максимизирует **зазор** (margin) между плоскостью и данными из обучающей выборки.

Если классы линейно разделимы и каждый содержит не менее одного элемента, то оптимальная разделяющая гиперплоскость единственна.

# Разделяющая полоса



# Поиск лучшей полосы



# Как определить ширину полосы?

Без доказательства:

$$M = \frac{2}{\|\mathbf{w}\|} = \frac{2}{w_1^2 + w_2^2 + \dots + w_m^2}$$

Формулировка задачи оптимизации:

$$\frac{2}{\|\mathbf{w}\|} \rightarrow \max_{\mathbf{w}}$$

при условии:

$$\text{для } y_i = +1 : \quad \mathbf{w}^T \mathbf{x} + b \geq 1$$

$$\text{для } y_i = -1 : \quad \mathbf{w}^T \mathbf{x} + b \leq -1$$

# Задача оптимизации

$$\frac{\|\mathbf{w}\|^2}{2} = \frac{1}{2}(w_1^2 + w_2^2 + \dots + w_m^2) \rightarrow \min_{\mathbf{w}}$$

при условии:

$$y_i (\mathbf{w}^T \mathbf{x} + b) \geq 1$$

Это задача квадратической оптимизации с линейными ограничениями!

# Задача оптимизации

Функция Лагранжа:

$$\mathcal{L}(\mathbf{x}, \mathbf{w}, b, \alpha) = \frac{1}{2} \sum_{i=1}^m w_i^2 - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x} + b) - 1)$$

$\alpha_i, i = 1, \dots, n$  - множители Лагранжа.

Необходимые условия седловой точки функции Лагранжа

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^n \alpha_i y_i = 0, \quad \frac{\partial \mathcal{L}}{\partial w_k} = w_k - \sum_{i=1}^n \alpha_i y_i x_i^{(k)} = 0, \quad k = 1, \dots, m$$

# Задача оптимизации

Подставляя условия седловой точки в функцию Лагранжа, получаем двойственную задачу

$$\max \left( \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right)$$

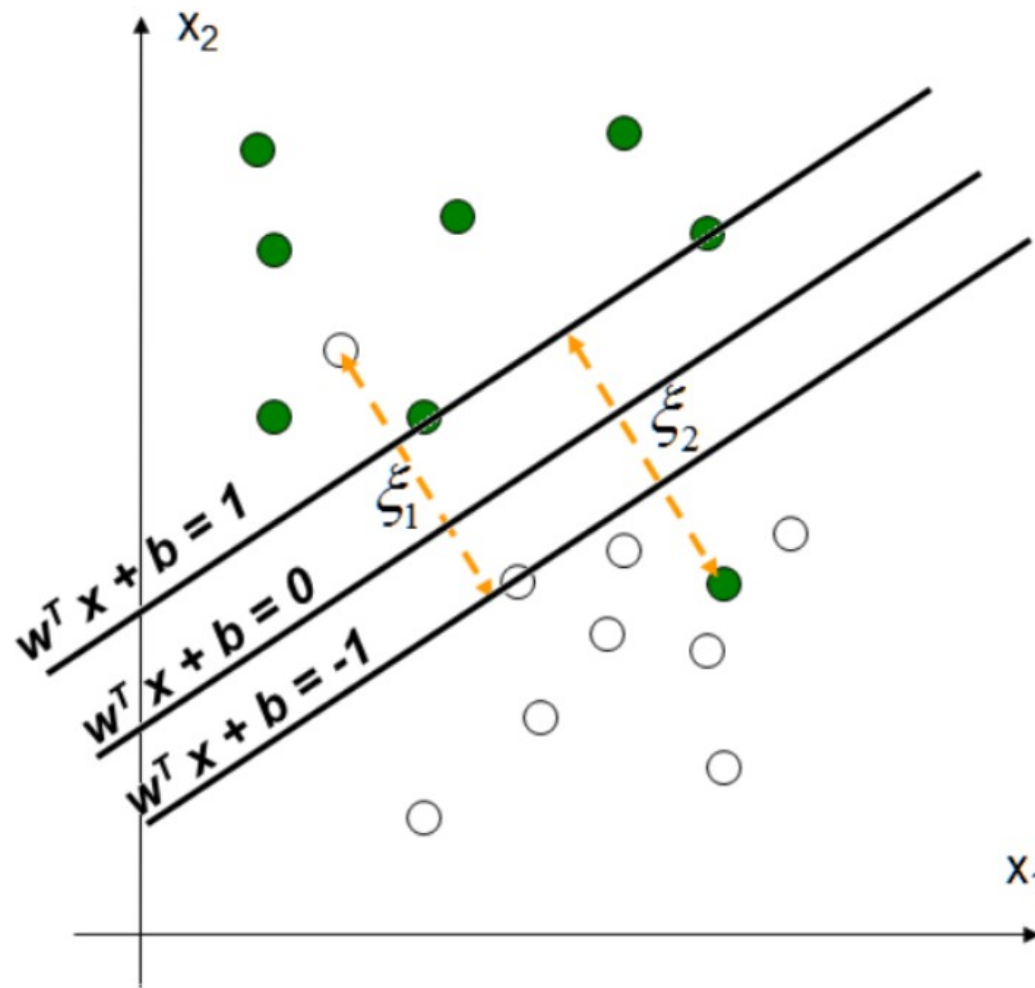
при ограничениях

$$\alpha_i \geq 0, i = 1, \dots, n, \sum_{i=1}^n \alpha_i y_i = 0.$$

Разделяющая функция:

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^n \alpha_i \mathbf{x}_i^T \mathbf{x} + b$$

# Данные линейно не разделимы



Вспомогательные переменные  $\xi_i$  (неотрицательные ошибки) могут быть добавлены.



# Переформулирование задачи оптимизации

$$\frac{\|\mathbf{w}\|}{2} = \frac{1}{2}(w_1^2 + w_2^2 + \dots + w_m^2) \rightarrow \min_{\mathbf{w}}$$

при условии:  $y_i (\mathbf{w}^T \mathbf{x} + b) \geq 1, i = 1, \dots, n.$



$$\frac{\|\mathbf{w}\|}{2} + C \sum_{i=1}^n \xi_i$$

при условии:

$$y_i (\mathbf{w}^T \mathbf{x} + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, n.$$

$C$  - штрафной параметр

# Переформулирование задачи оптимизации

$$\max_{\alpha} \left( \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right)$$


при ограничениях

$$0 \leq \alpha_i \leq C, i = 1, \dots, n, \sum_{i=1}^n \alpha_i y_i = 0.$$

Разделяющая функция:

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^n \alpha_i \mathbf{x}_i^T \mathbf{x} + b$$

# Сложный случай




Как построить разделительную плоскость?

# Ядра и спрямляющие пространства

Необходимо перейти от исходного пространства  $X$  в другое большей размерности, называемое **спрямляющим пространством**, с помощью некоторого отображения  $\Phi$ .

# Ядра и спрямляющие пространства



$$\varphi : (x_1, x_2) \rightarrow (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$

$$\left(\frac{x_1}{a}\right)^2 + \left(\frac{x_2}{b}\right)^2 = 1 \rightarrow \frac{z_1}{a^2} + \frac{z_3}{b^2} = 1$$

# Ядра и спрямляющие пространства

- Чтобы в двумерном пространстве с координатами  $(x_1, x_2)$  решить задачу классификации квадратичной функцией, надо перейти в пятимерное пространство:

$$(x_1, x_2, x_1 \cdot x_2, x_1^2, x_2^2)$$

- Если решить задачу линейного разделения в этом новом пространстве, тем самым решится задача квадратичного разделения в исходном.
- Отображение

$$\varphi : \mathbb{R}^2 \rightarrow \mathbb{R}^5 : \varphi(x_1, x_2) = (x_1, x_2, x_1 \cdot x_2, x_1^2, x_2^2)$$

- Вектор в  $\mathbb{R}^5$  теперь соответствует квадратичной кривой общего положения в  $\mathbb{R}^2$ , а функция классификации выглядит как

$$f(\mathbf{x}) = \text{sign}(\varphi(\mathbf{w})\varphi(\mathbf{x}) - b)$$

# Ядра и спрямляющие пространства

Разделяющая плоскость в спрямляющем пространстве:


$$g(\mathbf{x}) = \sum_{i=1}^n \alpha_i \mathbf{x}_i^T \mathbf{x} + b \rightarrow g(\mathbf{x}) = \sum_{i=1}^n \alpha_i \varphi(\mathbf{x}_i)^T \varphi(\mathbf{x}) + b$$

Произведение  $\varphi(\mathbf{x}_i)^T \varphi(\mathbf{x})$  играет необыкновенную роль.  
Ядро

$$K(\mathbf{x}_i, \mathbf{x}_j) = \varphi(\mathbf{x}_i)^T \varphi(\mathbf{x}_j).$$

# Ядра в методе опорных векторов

## Линейное ядро




$$K(w, x) = \langle w, x \rangle$$



# Ядра в методе опорных векторов


## Линейное ядро



$$K(w, x) = \langle w, x \rangle$$

# Ядра в методе опорных векторов


## Полиномиальное ядро



$$K(w, x) = (\gamma \langle w, x \rangle + r)^d$$

# Ядра в методе опорных векторов

## Радиальное ядро



$$K(w, x) = e^{-\gamma \|w - x\|^2}$$

# Ядра в методе опорных векторов

## Ядра и библиотеки

- › LibSVM — можно выбирать ядра
- › LibLinear — только линейное ядро
- › Scikit-learn — обёртка над LibSVM и LibLinear
- › Vowpal Wabbit — только линейное ядро

# Scikit-learn code

```
import numpy as np
X = np.array([[-1, -1], [-2, -1], [1, 1], [2, 1]])
y = np.array([1, 1, 2, 2])
```

```
from sklearn.svm import SVC
clf = SVC(kernel='linear')
clf = clf.fit(X, y)
```

```
prediction = clf.predict([[0, 6]])
```

# Преимущества и недостатки SVM

- Преимущества SVM:
  - Задача выпуклого квадратичного программирования имеет единственное решение.
  - Позволяет рассматривать различные виды нелинейности, изменяя ядра или их параметры.
- Недостатки SVM:
  - Неустойчивость к шуму.
  - Нет общих подходов к оптимизации ядра под задачу.
  - Приходится подбирать параметр  $C$ .
  - Нет отбора признаков.